



# Proyecto Final Integrado

---

Machine Learning - Deep Learning  
Máster Universitario en Inteligencia Artificial  
Curso académico 2025/2026

Diego Canales Aguilera

Antonio M. Durán Rosal

# Proyecto Final Integrado

## 1. Introducción

En la industria actual, los modelos más robustos rara vez dependen de una sola fuente de datos. La capacidad de integrar información heterogénea, combinando la estructura de los **datos tabulares** con la riqueza semántica de las **imágenes**, es una habilidad crítica para un profesional en este campo.

El objetivo de esta práctica es diseñar, entrenar y comparar arquitecturas que fusionen técnicas de **Machine Learning Clásico** (KNN, Regresiones, Trees, Ensembles...) con **Deep Learning** (CNNs, Transfer Learning...).

**El trabajo deberá ser resuelto en grupos de tres personas.**

## 2. Dataset

Para realizar la práctica, debéis seleccionar un dataset que contenga obligatoriamente **imágenes** y **datos tabulares** (metadatos) asociados a esas imágenes para predecir un objetivo (*Target*).

Tenéis dos opciones:

### 1. Elegir uno de los recomendados:

- **Real Estate:** Predecir precio de casas usando características (habitaciones, zona) + fotos. ejemplo 1, ejemplo 2
- **PetFinder:** Predecir adopción de mascotas usando ficha técnica + fotos. dataset
- **ISIC Melanoma:** Clasificación de lesiones cutáneas usando datos del paciente + dermatoscopia. dataset

### 2. Propuesta propia:

Podéis buscar vuestro propio dataset (Kaggle, UCI, etc.) siempre que cumpla con los requisitos mixtos. *Deberá ser validado brevemente por los profesores antes de empezar.*

### 3. Desarrollo Teórico

El proyecto debe estructurarse en dos bloques de experimentación incremental:

#### 3.1. Bloque A: Modelos Unimodales (Benchmarks)

Antes de fusionar, debéis establecer la línea base de rendimiento por separado.

- **Solo ML (Tabular):** Preprocesamiento de datos (Cleaning, Encoding, Scaling) y entrenamiento de modelos clásicos (KNN, Regresiones, Árboles de Decisión, Random Forest, XGBoost, LightGBM, etc.).
- **Solo DL (Imágenes):** Entrenamiento de una Red Neuronal Convolucional (CNN). Se valora el uso de *Transfer Learning* (ResNet, EfficientNet, VGG) frente a entrenar desde cero, dada la limitación de datos.

#### 3.2. Bloque B: Arquitecturas Híbridas (Fusión)

Debéis implementar y comparar **al menos DOS** de las siguientes estrategias de fusión:

1. **Fusión Temprana (Feature Extraction):** Usar la CNN (sin la capa de clasificación) para extraer un vector de características (*embedding*) de cada imagen. Añadir este vector como nuevas columnas al dataset tabular y entrenar un modelo potente de ML (ej. Gradient Boosting) con todo junto.
2. **Fusión Tardía (Ensembling):** Entrenar los modelos de Tabular y de Imagen por separado y combinar sus predicciones finales (probabilidades) mediante media ponderada, votación o un meta-modelo (*Stacking*).
3. **Red Neuronal Mixta (End-to-End):** Crear una arquitectura en PyTorch con dos ramas de entrada (Inputs numéricos + Inputs de imagen) que se concatenen en capas ocultas densas y se entrenen simultáneamente.

## 4. Entregables

### 4.1. Notebook de Código (Python)

Debe ser ejecutable, estar bien documentado y mostrar el flujo de trabajo:

- Carga de datos y EDA (*Análisis Exploratorio*) rápido: ¿Aportan las imágenes información visual obvia que no esté en la tabla?
- Preprocesamiento diferenciado para tabular e imágenes.
- Implementación de modelos A y B.
- Comparación de métricas.

### 4.2. Informe de Resultados (PDF)

Una de las finalidades de estas asignaturas es saber **interpretar los resultados** obtenidos y **justificar las decisiones** adoptadas durante el proceso de modelado y evaluación. Por ello, la calificación de esta práctica valorará tanto la **calidad del código desarrollado** como la **claridad y profundidad de las explicaciones** incluidas en cada apartado solicitado. Al menos, el análisis debe incluir:

- **Tabla Resumen:** Comparad las métricas que consideréis oportunas: *Solo Tabular* vs. *Solo Imagen* vs. *Modelos Híbridos*.
- **Discusión Crítica:**
  - ¿Mejora el modelo híbrido a los modelos por separado? ¿Por qué?
  - ¿Qué estrategia de fusión funcionó mejor?
  - Coste computacional vs. Ganancia de rendimiento.
  - Todo lo que hayáis aprendido en ambas asignaturas.

## 5. Evaluación

Esta práctica supone un máximo de un 30 % de las asignaturas Machine Learning y Deep Learning. La evaluación se llevará a cabo aplicando la siguiente fórmula:

$$Nota = 60\% \cdot Profesor + HC(20\%Coevaluacion) + HA(20\%Autoevaluacion)$$

siendo  $HC$  la ponderación de la Heteroevaluación con respecto a la evaluación de vuestros compañeros, y  $HA$  con respecto a vosotros mismos. Será 1 si la diferencia de vuestra nota con respecto a la mía es menor o igual a 1 punto, 0.5 si la diferencia está en el intervalo  $(1, 2.5]$ , o 0 si es mayor a 2.5.

### 5.1. Justificación del modelo de evaluación

El modelo de evaluación propuesto es especialmente adecuado en el contexto de un máster universitario en Inteligencia Artificial (IA), y en particular en asignaturas como *Machine Learning* y *Deep Learning*, por las siguientes razones:

- **Alineación con competencias avanzadas:** En un máster de IA no solo se evalúa el dominio técnico, sino también competencias transversales como el pensamiento crítico, la capacidad de autoanálisis, la evaluación de soluciones ajenas y la responsabilidad profesional. La combinación de evaluación del profesor, coevaluación y autoevaluación permite medir estas dimensiones de forma integrada.
- **Simulación de contextos profesionales y científicos:** En el ámbito de la IA, los estudiantes deberán justificar modelos, revisar trabajos de otros investigadores (peer review) y evaluar su propio desempeño en proyectos complejos. Este sistema reproduce dinámicas reales del entorno académico y profesional.
- **Control del sesgo y rigor académico:** El uso de los coeficientes  $HC$  y  $HA$  introduce un mecanismo corrector que premia la objetividad y penaliza desviaciones excesivas respecto a la evaluación del profesor, garantizando rigor y evitando inflaciones injustificadas de la nota.
- **Aprendizaje colaborativo:** La coevaluación obliga a los estudiantes a analizar críticamente el trabajo de sus compañeros, lo que refuerza la comprensión de los criterios de calidad en modelos, experimentos y resultados en IA.

## 5.2. Ejemplo de mala evaluación

Supongamos un estudiante que entrega una práctica de *Deep Learning* con los siguientes problemas:

- Arquitectura del modelo mal justificada.
- Errores conceptuales en la función de pérdida.
- Resultados no reproducibles y sin análisis estadístico.

El profesor asigna una nota de 4,5. Sin embargo:

- El propio estudiante se autoevalúa con un 9.
- Sus compañeros le asignan una media de 8,5 sin un análisis crítico real.

La diferencia con la nota del profesor es mayor de 2,5 puntos, por lo que:

$$HA = 0, \quad HC = 0$$

La nota final queda fuertemente determinada por la evaluación del profesor, evidenciando que la autoevaluación y coevaluación no han sido objetivas. Este caso ejemplifica una **mala evaluación**, basada en percepciones infladas y falta de criterio técnico.

## 5.3. Ejemplo de buena evaluación

Consideremos ahora una práctica bien desarrollada:

- Modelo correctamente diseñado y justificado.
- Experimentos reproducibles con validación cruzada.
- Análisis crítico de resultados y limitaciones.

El profesor asigna una nota de 8,0. En este caso:

- El estudiante se autoevalúa con un 7,8.
- La coevaluación media de sus compañeros es 8,2, con comentarios técnicos detallados.

La diferencia con la nota del profesor es menor o igual a 1 punto, por lo que:

$$HA = 1, \quad HC = 1$$

La nota final refleja coherencia entre las distintas fuentes de evaluación. Este escenario representa una **buena evaluación**, caracterizada por objetividad, madurez académica y alineación con los estándares de un máster en IA.